

Avaliação do uso de modelos multimodais na melhoria de visualização de dados com base em boas práticas da literatura

Denilson Deivid Lima Silva

denilson.silva@ccc.ufcg.edu.br

Universidade Federal de Campina Grande (UFCG)
Campina Grande, Paraíba, Brasil

Maxwell Guimarães de Oliveira

maxwell@computacao.ufcg.edu.br

Universidade Federal de Campina Grande (UFCG)
Campina Grande, Paraíba, Brasil

Resumo

A qualidade das visualizações de dados é determinante para a comunicação científica e a tomada de decisão. Com o avanço dos modelos de linguagem de grande escala (LLMs) e dos modelos de visão-linguagem, ou modelos multimodais (VLMs), surge a oportunidade de investigar e entender como essas ferramentas são capazes de identificar e corrigir erros em visualizações gráficas com base em boas práticas da literatura. Este trabalho avalia o desempenho de quatro modelos na realização de duas tarefas automatizadas envolvendo visualização de dados: GPT-5.4, Claude Sonnet 4.6, Gemini 3.1 Flash e DeepSeek-V3.2. Sendo realizado em duas partes: 1) identificação de oito erros visuais em gráficos; 2) geração de versões corrigidas de tais erros. Para a tarefa de identificação, foram aplicadas três técnicas de prompt (zero-shot, few-shot e chain-of-thought) em três execuções independentes para cada setup experimental, variando modelo, tipo de erro e prompt. Assim, totalizando 288 execuções analisadas e avaliadas com base em um indicador binário de acerto/erro e uma nota para a qualidade da resposta de cada modelo, baseada na escala Likert. Os resultados indicam que GPT-5.4 e Claude Sonnet 4.6 se destacaram como os modelos mais robustos, resolvendo bem as tarefas avaliadas, enquanto o DeepSeek-V3.2 apresentou desempenho consistentemente inferior, inclusive com respostas alucinatórias. Na atividade de correção, os dois melhores modelos também obtiveram alto desempenho, com o GPT-5.4 demonstrando maior consistência qualitativa. Conclui-se que esses modelos possuem potencial relevante para análise e melhoria automatizada de visualizações de dados, embora limitações específicas por modelo e por tipo de gráfico ainda demandem investigação aprofundada.

1 INTRODUÇÃO

A qualidade das visualizações de dados possuem grande relevância na comunicação científica e na tomada de decisão em diversas áreas, sendo de grande impacto na Ciência de Dados, tendo destaque subtópicos como: Machine Learning, Data Storytelling e Business Intelligence. Gráficos mal construídos são capazes de induzir ao erro e interpretações errôneas, mesmo que partes subjacentes da visualização estejam corretas [1]. Paralelamente, temos a rápida evolução dos modelos de linguagem de grande escala (LLMs) e dos modelos de visão-linguagem (VLMs), também conhecidos como modelos multimodais, que possuem capacidade para geração de legenda para imagens, tradução textual e sumarização, sendo características bem consolidadas [21, 22]. Além disso, esse poder de processamento nos motiva a investigar e compreender a eficácia dessas tecnologias no âmbito de representações gráficas que possuem embasamento bem definido na literatura.

Nesse quesito, Vázquez [2] descreve questionamentos sobre o quanto os modelos multimodais estariam prontos para tarefas de visualização, destacando que mesmo tendo resultados promissores em contextos simples, ainda há deficiências consideráveis, como gráficos confusos e mal formatados, exigindo raciocínio visual mais profundo. De modo semelhante, Bendeck & Stasko [3] consideraram estudos empíricos sobre o GPT-4 em tarefas de literacia visual, compreendendo que o modelo conquistou desempenho inferior aos humanos e ainda possui várias limitações na sua alfabetização visual. Com isso, reforçando a comprovação de que esses modelos ainda possuem desafios nas estruturas de leitura e interpretação gráfica.

Diante desse cenário, este trabalho tem como objetivo avaliar se os modelos multimodais são capazes de identificar erros ou más práticas comuns em visualização de dados, com base nas boas práticas descritas na literatura, em especial, sob o olhar de Claus Wilke [16] e Cole Knaflitz [20], principais autores que embasam a disciplina de Visualização de Dados, ofertada para o curso de Ciência da Computação da UFCG. Adicionalmente, este trabalho também tem como objetivo verificar se tais modelos conseguem corrigir esses problemas de forma automatizada, gerando novas visualizações, corrigidas e sem introduzir novos problemas.

As principais contribuições deste estudo consistem em: (i) uma metodologia sistemática e reprodutível para avaliação de modelos multimodais em tarefas de análise visual, fundamentada em princípios teóricos consolidados; (ii) uma comparação empírica entre quatro modelos e três técnicas de prompt; e (iii) a constatação de que esses modelos apresentam potencial relevante tanto para identificação quanto para correção de problemas comuns em visualizações de dados.

Durante a realização deste trabalho, utilizou-se a ferramenta de Inteligência Artificial Trae para apoio em correção gramatical, revisão de clareza textual, reformulação pontual de trechos, auxílio na depuração de código e apoio técnico na organização de tabelas, gráficos e descrições analíticas. O conteúdo gerado foi revisado criticamente, ajustado sempre que necessário e validado pelo autor, que assume total responsabilidade pela precisão técnica e pelo conteúdo apresentado.

O restante deste artigo está organizado da seguinte forma: a Seção 2 expõe a fundamentação teórica, abordando os conceitos de LLMs, modelos de visão-linguagem, engenharia de prompt e boas práticas em visualização de dados; a Seção 3 apresenta os trabalhos relacionados, contextualizando as abordagens existentes na literatura sobre o uso de LLMs e VLMs em tarefas de visualização; a Seção 4 descreve o método adotado, detalhando as tarefas de avaliação, os prompts utilizados e os critérios de análise; a Seção 5

apresenta e discute os resultados obtidos nas duas tarefas do estudo; e a Seção 6 traz as conclusões e sugestões para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Para uma análise de visualização de dados utilizando modelos multimodais, este trabalho fundamenta-se em tópicos ligados diretamente ao tema, com foco em aparatos bibliográficos mais recentes.

2.1 Modelos de Linguagem de Grande Escala (LLMs)

Os modelos de linguagem de grande escala (LLMs) representam um marco significativo na área de Inteligência Artificial (IA), tendo como um destaque a arquitetura transformer. Esses modelos são treinados a partir de enormes volumes de dados textuais e possuem bilhões de parâmetros, dando à tecnologia da IA o poder de realizar tarefas complexas, como geração de texto, tradução e análise de dados.

A arquitetura transformer foi proposta por Ashish Vaswani et al. [9], ela revolucionou o Processamento de Linguagem Natural (PLN) ao substituir a abordagem recorrente por mecanismo baseado em atenção. Diferente dos modelos anteriores, como Redes Neurais Recorrentes (RNNs), o transformer processa os dados de forma paralela, permitindo maior eficiência computacional e na melhoria da captura de dependências de longo alcance em sequências textuais.

O principal componente dessa arquitetura é o mecanismo de autoatenção (self-attention), ele permite atribuir diferentes pesos às palavras de uma sequência e compreender quais palavras têm maior importância dentro do contexto. Além disso, outra característica importante é sua composição em camadas de atenção e redes neurais feedforward, que são divididas em dois blocos essenciais para seu funcionamento, o codificador (encoder) e o decodificador (decoder), sendo estas responsáveis pela representação e geração de sequências.

A partir dessa arquitetura, temos uma evolução nas LLMs, que ampliam as escalas do modelo tanto em dados quanto em parâmetros. De acordo com Kumar [10], as LLMs têm sido aplicadas em diversas áreas, dentre elas, processamento de linguagem natural, medicina, educação e principalmente a generalização de código, demonstrando uma grande capacidade de generalização.

No contexto de aprendizagem de máquina, a generalização está ligada à capacidade de um modelo de adquirir um conhecimento durante seu treinamento sobre dados não vistos. Conforme Tom B. Brown et al. [11], LLMs são capazes de realizar tarefas em regime de pouca informação, evidenciando sua habilidade de generalizar para novos contextos com mínima adaptação.

Além disso, Minaee et al. [12] cita que o desempenho desses modelos está proporcionalmente relacionado a escala, sobre o que são chamadas de scaling laws, nas quais os modelos maiores apresentam um melhor desempenho.

No contexto de LLMs, um dos modelos utilizados foi o DeepSeek-V3.2, que é declarado no card oficial como modelo exclusivamente textual, pois não possui encoder de visão integrado ao seu transformer. Embora a documentação técnica oficial do DeepSeek-V3.2 [30] classifique o modelo como text-only, sem suporte nativo à entrada visual, análises de terceiros e relatos de usuários apontam que, na

interface de chat oficial, o sistema é capaz de responder sobre o conteúdo de imagens enviadas [31]. Isso é consistente com a hipótese de que a plataforma realiza uma etapa intermediária de extração de texto (via OCR) antes de submeter o conteúdo ao modelo de linguagem, já que o próprio V3.2 não possui um encoder visual integrado. Essa arquitetura de pipeline, no entanto, não é descrita em documentação técnica publicada oficialmente pela DeepSeek.

2.1.1 Modelos de Visão-Linguagem (VLMs). Os modelos multimodais, conhecidos como Vision-Language Models (VLMs), ampliam as capacidades das LLMs ao integrar informações textuais e visuais em um único modelo [7]. Os modelos utilizados nesta pesquisa classificados oficialmente como VLMs são: Claude Sonnet 4.6, GPT-5.4 e Gemini 3.1 Flash. Estes possuem capacidade nativa de processamento multimodal de texto e imagem conforme documentado em seus system cards e model cards oficiais [23, 24, 25]. Embora os VLMs tenham evoluído significativamente, problemas associados ao alinhamento multimodal e à equivalência semântica entre tokens visuais e linguísticos ainda representam limitações importantes para a compreensão contextual e inferência semântica desses modelos [8].

2.2 Engenharia de Prompt

A engenharia de prompt trata-se do processo de criação e otimização de instruções textuais fornecidas a modelos de linguagem, com o objetivo de aumentar a qualidade e precisão de suas respostas. De acordo com o Prompt Engineering Guide [13], a forma como o prompt é estruturado influencia de forma direta o resultado da resposta do modelo, sendo um fator determinante para tarefas de raciocínio e interpretação.

Entre as técnicas utilizadas, podemos destacar o zero-shot prompting, em que o modelo realiza uma tarefa sem exemplos prévios, utilizando apenas dos dados de treinamento e sua capacidade de generalização [11]. Já o few-shot prompting consiste na inclusão de exemplos no prompt, seja por texto ou imagem, permitindo ao modelo compreender padrões e melhorar sua resposta [11]. Por fim, a técnica chain-of-thought (CoT), proposta por Wei et al. [14], estabelece tarefas de raciocínio, incentiva o modelo a executar um passo a passo e tal recurso pode aumentar significativamente a capacidade do modelo de resolver problemas complexos.

Além disso, é importante destacar que a escolha da técnica de prompt impacta diretamente no desempenho dos modelos, especialmente nas tarefas que envolvem análise estruturada de dados e inferência textual [15].

2.3 Boas Práticas em Visualização de Dados

A visualização de dados tem o objetivo de representar informações graficamente, comunicando padrões e apoiando na tomada de decisão. De acordo com Claus Wilke [16], visualizações eficazes devem priorizar clareza, precisão e foco na mensagem principal. Estudos de Hehman & Xie [17] citam que a escolha adequada da representação visual influencia diretamente na compreensão dos dados. Nesse tópico, a literatura destaca que erros no design são comuns e também podem comprometer a interpretação das informações [18].

Na visão de Knaflitz [20], os dados devem ir além de exibir apenas números, defendendo a ideia de que o objetivo central é comunicar uma mensagem clara. Com isso, a autora destaca abordagens como:

evitar uso de cor desnecessariamente (uso de cor que não transmite nenhuma informação); evitar saturação em excesso, ajudando a diminuir a carga cognitiva. Por fim, em seu livro *Storytelling com dados*, Knaflitz destaca que um bom gráfico funciona como uma história, direcionando o leitor a um fluxo de informações que constroem uma narrativa de hierarquia visual.

Os principais fundamentos estão baseados na seleção adequada do tipo de gráfico, uso correto de escalas e redução de elementos desnecessários, assim, melhorando a comunicação gráfica. Ademais, recomendações recentes enfatizam o uso de cores apropriadas e visualizações que melhor expressem relações e distribuições [17].

Erros comuns como gráfico de barras em que a medida quantitativa não inicia do zero, uso errôneo de cores e sobrecarga visual são amplamente documentados e podem atrapalhar no entendimento da informação. Esses princípios são amplamente abordados na literatura recente, especificamente os que analisam falhas comuns em visualizações científicas [19].

Dessa maneira, a adoção de boas práticas, conforme destacado por Claus Wilke [16], torna-se crucial em qualquer visualização que preza por qualidade e clareza.

3 TRABALHOS RELACIONADOS

Nesta seção, serão apresentados os trabalhos ligados diretamente ao tema principal deste estudo, eles tem objetivo de contextualizar e demonstrar abordagens existentes na literatura. São discutidos dois estudos principais, ambos focando na investigação do uso de modelos de linguagem e modelos multimodais na análise e melhoria de visualização de dados, destacando suas contribuições, limitações e diferenças em relação à proposta deste trabalho.

No estudo de Khan et al. [4], o foco está no potencial de modelos de linguagem de grande escala (LLMs) em tarefas que extrapolam a geração textual, incluindo a interpretação e produção de visualizações de dados. O trabalho propõe uma avaliação sistemática da capacidade desses modelos em duas vertentes: geração de visualizações partindo de descrições textuais e interpretação de gráficos com base em informações visuais e semânticas.

De forma metódica, o estudo adota tarefas que envolvem uma gama de gráficos (pizza, barras, linhas e dispersão), sendo avaliados sob diversos critérios como de corretude, coerência e fidelidade.

Como resultado, embora as LLMs e VLMs apresentem bom desempenho em tarefas simples e estruturadas, a sua resposta decai nitidamente quando os cenários exigem uma maior capacidade de raciocínio visual e interpretação contextual. Pode-se observar que os modelos cometem erros na leitura de relações quantitativas e na identificação de inconsistências visuais, discretizando o fenômeno de alfabetização visual.

Outro destaque parte do trabalho de Bonás et al. [5], que trata sobre um pipeline estruturado para interpretação, diagnóstico e correção de diversos gráficos, utilizando modelos que integram informações visuais e textuais, como Gemma3-12B e GPT-OSS:20B.

A proposta do autor consiste numa extração subjacente da visualização, o que inclui eixos, legendas e variáveis presentes no gráfico. A partir disso, os modelos utilizados têm o objetivo de encontrar inconsistências ou inadequações nos gráficos. Por fim, o modelo ainda é orientado a realizar uma melhoria na imagem, focando em pontos como clareza, precisão e efetividade comunicativa.

O estudo pode demonstrar que VLMs são capazes de realizar tarefas complexas de interpretação visual, além de identificar o tipo de gráfico mais adequado. No entanto, ainda é verídico que tal capacidade ainda está sob limitados fatores, como ambiguidade semântica, erros de inferência e dependência da qualidade da análise inicial.

Mesmo com uma análise detalhada, o estudo de Khan et al. [4] evidencia uma proporção geral, não abordando de forma específica a identificação de erros em gráficos com base em princípios teóricos consolidados de design. Nesse sentido, o presente estudo se diferencia ao focar na detecção de falhas na visualização de dados fundamentada em boas práticas da literatura, especificamente nas diretrizes descritas por Claus Wilke, além de incorporar uma avaliação estruturada do desempenho desses modelos. Além disso, diferente do trabalho de Bonás et al. [5], que propõe um pipeline de múltiplas etapas — reconstrução estrutural do gráfico, diagnóstico automatizado e correção iterativa —, este estudo também contempla a identificação e melhoria na visualização, porém de forma não automatizada e sem uma arquitetura encadeada de processamento, o que pode gerar novos resultados.

4 AVALIAÇÃO EXPERIMENTAL

Para conseguir alcançar os objetivos deste estudo, foi desenvolvido um método de avaliação experimental estruturado em duas partes principais: (i) focada em analisar se os modelos conseguem identificar os erros de visualização com base em boas práticas da literatura e (ii) focada em analisar se os modelos multimodais conseguem corrigir gráficos contendo tais erros, sem inserir novos erros.

4.1 Tarefa I: Identificação dos erros

Como pressuposto de análise, foram escolhidos oito gráficos com problemas clássicos de visualização. Os erros encontrados foram documentados em Tabela de mapeamento contendo: número sequencial, localização da figura de inspiração, tipo de gráfico analisado, descrição detalhada do erro e sugestão de correção. Além disso, para melhor representar os erros, foram criados oito gráficos originais baseados nos mesmos princípios e contextos das visualizações analisadas dos livros em questão, representando os mesmos erros, mas com dados e contextos distintos. Além disso, é válido destacar que a Tabela 1 contém um resumo com descrição e correção esperada do erro, sendo possível observar uma riqueza maior de detalhes através da tabela que se encontra no repositório do GitHub, com o link disponibilizado no rodapé da página.¹

Foi construída uma planilha de mapeamento que registra o desempenho de diferentes modelos em relação aos erros clássicos de visualização descritos nos oito gráficos selecionados. A planilha foi estruturada em um arranjo fatorial, combinando: (i) quatro modelos de linguagem (GPT-5.4, Claude Sonnet 4.6, Gemini 3.1 Flash e DeepSeek-V3.2), (ii) três estratégias de prompt (Zero-shot, Few-shot e Thought-Chain) e (iii) três execuções independentes de teste, mantendo os mesmos oito itens de gráfico (1 a 8) em todas as condições. Para cada combinação de modelo, foram registrados dois indicadores: um indicador binário de acerto (ACERTO), codificado como 1 para resposta correta e 0 para resposta incorreta;

¹<https://github.com/denilsondeivid/Avaliacao-do-uso-de-LLMs-em-Visualizacao-de-Dados>

Tabela 1: Descrição dos erros gráficos selecionados para estudo.

Gráfico	Tipo de Gráfico	Descrição do erro	Correção esperada	Referência
1	BARRAS	Título longo e rotacionado no eixo X	Troca do eixo X pelo Y, deixando o texto na horizontal	[16], Fig. 6.2
2	BARRAS	Grandeza numérica desordenada e de difícil compreensão	Ordenar por valores de dados crescentes ou decrescentes	[16], Fig. 6.5
3	BARRAS AGRUPADAS	Informação em excesso comprometendo o entendimento	Separação do gráfico principal em gráficos que agrupam cada categoria	[16], Fig. 6.8
4	HISTOGRAMA	Empilhamento de dados sem clareza em uma das categorias	Utilizar gráfico de densidade com histogramas separados	[16], Fig. 7.6
5	PIZZA	Excesso de categorias	Utilizar gráfico de barras	[16], Fig. 10.1
6	BARRAS	Utilização de muitos zeros no eixo X	Simplificar com potência	[20], Fig. 3.19
7	BARRAS	Não iniciar os eixos X e Y na posição 0	Iniciar eixo X e Y na posição 0	[16], Fig. 17.1
8	BARRAS	Utilização de mais de uma cor sem transmitir informação adicional	Redução da escala de cor	[16], Fig. 19.3

e uma nota na escala Likert. Dessa maneira, temos uma pesquisa constituída por um total de 288 cenários para análise. A justificativa da realização de três rodadas independentes de execução (com 96 cenários cada) se dá pela importância de verificar a consistência dos dados, se há variação significativa dos resultados de cada cenário entre as rodadas, tornando assim o estudo mais robusto.

A Tabela 2 apresenta os prompts criados para os cenários deste estudo. As técnicas zero-shot, few-shot e Thought Chain foram selecionadas para compreender, através de diferentes estratégias de estímulo, como elas influenciam na análise dos erros visuais. É importante ressaltar que, independente da técnica utilizada, em nenhum dos exemplos empregados nos prompts foi inserido um erro específico que coincidissem com os erros presentes nos oito tipos de gráficos de avaliação, de forma a testar a capacidade de generalização dos modelos em identificar problemas visuais não previamente exemplificados.

Para a parte da análise de respostas geradas, foi adotada uma nota Likert de cinco pontos, utilizada para mensurar a qualidade percebida da resposta, envolvendo questões subjetivas como clareza, adequação e completude, independentemente do acerto. A semântica de pontos dessa métrica foi definida da seguinte forma:

5 pontos: o modelo identifica o erro-alvo, apresenta justificativa correta e sugere novas formas de melhoria na visualização;

4 pontos: o modelo identifica o erro-alvo, mas apresenta falhas na explicação, como adição de mudanças desnecessárias ou simplesmente não sugere o gráfico mais adequado para a visualização;

3 pontos: o modelo não identifica o erro-alvo, mas apresenta uma análise útil e valiosa em relação ao gráfico;

2 pontos: o modelo não identifica o erro-alvo e apresenta uma análise fraca;

1 ponto: o modelo não identifica o erro-alvo e sugere alterações que são ruins ou fora de contexto.

Em relação à avaliação das respostas, a análise foi realizada de forma manual, verificando: (a) acurácia na identificação do erro-alvo, classificada como acerto (1) ou erro (0), e (b) qualidade geral da resposta através da nota Likert que varia de um a cinco.

4.2 Tarefa II: Geração dos gráficos corrigidos

Na tarefa voltada para correção de erro, realizou-se uma única rodada de testes, avaliando os oito gráficos descritos na Tabela 1, utilizando apenas dois VLMs, os que apresentaram melhor desempenho na tarefa de identificação de erros. Além disso, esta tarefa também aplica três técnicas de prompt (zero-shot, few-shot e Thought Chain), e uma nota Likert para validação da qualidade dos gráficos corrigidos gerados pelos modelos. Em relação à descrição dos textos utilizados nas técnicas de prompt, eles seguem a mesma

Tabela 2: Técnicas de prompt e Mecanismos de Identificação de Erros.

Tipo de Técnica	Tipo de mecanismo	Prompt criado
<i>zero-shot</i>	O modelo não recebe exemplos anteriores ou contexto, deve-se basear no conhecimento pré treinado.	Analise o gráfico apresentado e identifique se há erros de visualização. Explique se houver erros.
<i>few-shot</i>	O modelo recebe um exemplo para se orientar em tom e nível de simplicidade esperada.	Gráfico: o gráfico de barras apresenta o eixo X começando em 5 enquanto o Y inicia em 0. Resposta: o gráfico apresenta um erro de escala, pois o eixo X deve começar em zero para que não haja distorção da percepção dos dados. Dessa forma, analise o gráfico apresentado e identifique se há erros de visualização. Explique se houver erros.
<i>Thought Chain Prompt (CoT)</i>	O modelo é incentivado a pensar num passo a passo e dividir a explicação em passos lógicos.	1-identifique o tipo do gráfico 2-verifique os eixos 3-avalie as cores 4-verifique distorções Com base nesse passo a passo, identifique se há erros no gráfico e realize uma explicação.

estrutura da Tabela 2, porém com os prompts adaptados para um novo objetivo: em vez de identificar e explicar os erros de visualização, o modelo é instruído a corrigir o gráfico e gerar uma nova versão sem os problemas identificados.

Na análise da qualidade das respostas produzidas (gráficos corrigidos), foi adotada uma segunda nota likert também com cinco pontos, seguindo a mesma estratégia de pontuação da tarefa anterior. A nota foi definida da seguinte forma:

- 5 pontos:** o modelo gera um gráfico corrigido, removendo completamente o erro-alvo sem introduzir novos erros visuais;
- 4 pontos:** o modelo gera um gráfico corrigido, mas com pequenas falhas visuais ou imprecisões;
- 3 pontos:** o modelo tenta corrigir o erro, mas o resultado fica parcialmente correto ou incompleto;
- 2 pontos:** o modelo não consegue corrigir adequadamente o erro e introduz novos problemas visuais;
- 1 ponto:** o modelo não consegue gerar um gráfico relevante ou sua resposta fica fora de contexto.

Em relação à avaliação de suas respostas, foi analisado: (a) capacidade do modelo em gerar um novo gráfico que removesse o erro identificado, e (b) presença de novos erros visuais introduzidos durante a geração, também quantificada pela nota. Esta abordagem manual garantiu avaliação contextual e interpretação precisa das respostas, considerando características que métricas automáticas podem não capturar.

4.3 Ferramentas e Softwares utilizados

Para a criação dos oito gráficos descritos na Tabela 1, utilizou-se o software Canvas, onde cada gráfico foi desenvolvido manualmente do zero, inspirando-se nos mesmos erros visuais identificados nos gráficos de referência extraídos dos livros Fundamentos da Visualização [16] e Storytelling com Dados [20]. Para os softwares e modelos de linguagem utilizados, respectivamente, temos: GPT-5.4, Claude Sonnet 4.6, Gemini 3.1 Flash e DeepSeek-V3.2 [24, 23, 25, 30]. Para otimizar o processo de avaliação dos modelos, considerando as limitações de recursos da interface do ChatGPT (que teria demandado tempo excessivo para identificação de erros e geração de gráficos), foi utilizado o software Trae² com o modelo GPT-5.4 integrado, permitindo maior eficiência na validação e análise das respostas dentro do cronograma de pesquisa.

Por fim, é necessário destacar que a seleção dos quatro modelos seguiu como critério a relevância e a popularidade desses modelos em benchmarks públicos e estudos recentes na literatura [27]. Todos os modelos possuem documentação pública disponível, com acesso à interface web e via API. A limitação a quatro modelos se justifica pelo escopo exploratório do estudo, que buscou comparar representantes das principais empresas desenvolvedoras de modelos de IA (OpenAI, Anthropic, Google e DeepSeek) sem esgotar a totalidade de modelos disponíveis no mercado, prática também adotada em trabalhos que restringem a comparação a três ou cinco modelos por questões de viabilidade metodológica [28].

²<https://www.trae.ai/>

4.4 Reprodutibilidade e transparência metodológica

Esta pesquisa foi estruturada de forma reprodutível e transparente em relação a seus métodos, alinhando-se aos princípios da FAIR [26]. Todos os seus componentes foram documentados de forma explícita e detalhada: (i) seleção e características dos oito gráficos analisados, com inspiração em referências teóricas consolidadas [16, 20], (ii) especificação completa das três técnicas de prompt utilizadas em ambas as tarefas, (iii) definição clara das notas para identificação de erros e geração de gráficos corrigidos, (iv) identificação precisa das versões dos modelos avaliados, (v) descrição detalhada do procedimento de avaliação manual em ambas as tarefas, e (vi) ferramentas utilizadas para criação e análise.

Além disso, todas as respostas geradas pelos modelos foram registradas e documentadas integralmente, incluindo: (a) respostas da tarefa (i) referentes à identificação de erros e justificativas dos modelos, e (b) gráficos corrigidos gerados na tarefa (ii). Estes dados foram organizados em repositório digital no GitHub, com descrição de tabelas, documentos e códigos utilizados durante o estudo, cuja documentação completa está disponível no link do rodapé.³

Esta documentação abrangente permite que qualquer pesquisador replique integralmente o estudo sob as mesmas condições, verifique os resultados, conduza análises comparativas independentes ou estenda a investigação com modelos diferentes, garantindo a integridade e confiabilidade dos achados.

4.5 Limitações do estudo

Este estudo apresenta algumas limitações que devem ser consideradas. Primeiramente, a amostra de VLMs avaliadas é limitada a apenas quatro modelos, não representando a totalidade de modelos disponíveis no mercado. Além disso, a tarefa (ii) de geração de gráficos foi conduzida com apenas uma rodada de testes, reduzindo o escopo comparativo em relação à tarefa anterior. A avaliação automatizada, embora útil para avaliar rapidamente o desempenho dos modelos em grande escala, não consegue captar totalmente a complexidade da compreensão e geração de linguagem, sendo a avaliação manual mais confiável para tarefas de geração aberta (não existe uma única resposta correta para comparar) [29]. Dessa maneira, todas as tarefas realizadas foram avaliadas manualmente. Por fim, não foi possível localizar documentação oficial da DeepSeek que descreve tecnicamente o pipeline de processamento de imagens utilizado na interface de chat. A inferência apresentada baseia-se em evidência indireta: a arquitetura conhecida do modelo (text-only) e o comportamento observado do produto.

5 ANÁLISE E DISCUSSÃO DE RESULTADOS

Para interpretar os resultados obtidos neste estudo, esta seção foi organizada em duas partes principais: (i) a análise do desempenho dos modelos na identificação de erros de visualização, considerando acurácia e qualidade das respostas, e (ii) a análise do desempenho na correção desses erros, observando tanto a capacidade de gerar gráficos corrigidos quanto a consistência qualitativa das respostas produzidas. A partir dessa divisão, busca-se discutir de forma

³<https://github.com/denilsondeivid/Avaliacao-do-uso-de-LLMs-em-Visualizacao-de-Dados>

comparativa os efeitos das diferentes técnicas de prompt e as particularidades de cada modelo ao longo das duas tarefas experimentais.

5.1 Desempenho comparativo dos modelos na identificação de erros de visualização

A Tabela 3 sintetiza, em um único quadro comparativo, duas dimensões centrais do desempenho dos modelos na etapa de identificação de erros: a acurácia por rodada e a nota média por técnica de prompt. Essa organização permite observar, de forma simultânea, tanto o comportamento dos modelos ao longo das repetições experimentais quanto a qualidade percebida das respostas produzidas sob diferentes técnicas de prompt. Em conjunto, os resultados reforçam que a comparação entre os modelos não deve ser feita apenas a partir da capacidade de acertar o erro-alvo, mas também pela forma como esse acerto é comunicado, justificado e sustentado textualmente.

No que se refere à acurácia por rodada, a Tabela 3 evidencia um comportamento distinto entre os modelos. O GPT-5.4 apresenta crescimento progressivo ao longo das execuções, saindo de 0,67 na primeira rodada para 0,92 na segunda e alcançando 0,96 na terceira. Esse padrão sugere alta estabilidade e forte capacidade de manter desempenho elevado com a repetição da tarefa. O Claude Sonnet 4.6, por sua vez, preserva um nível intermediário e relativamente estável, com 0,71 na primeira rodada, 0,79 na segunda e 0,71 na terceira, o que indica bom desempenho, ainda que sem a mesma trajetória observada no GPT-5.4. O Gemini 3.1 Flash apresenta o melhor resultado inicial, com 0,79 na primeira rodada, mas perdeu força nas execuções seguintes, caindo para 0,58 na segunda e recuperando-se parcialmente para 0,71 na terceira. Esse comportamento sugere maior oscilação entre rodadas, apontando para menor consistência quando comparado aos dois modelos mais bem posicionados. Já o DeepSeek-V3.2 permanece substancialmente abaixo dos demais em todas as rodadas, com 0,25, 0,29 e 0,38, respectivamente, o que indica limitações mais estruturais na tarefa de identificação de erros visuais.

Quando se observa a nota média por técnica de prompt, a Tabela 3 mostra que o GPT-5.4 também ocupa a posição de maior destaque qualitativo, mantendo notas elevadas em todas as abordagens de prompt. Seu melhor resultado ocorreu em Zero-shot, com 4,71, seguido por Thought-Chain, com 4,63, e Few-shot, com 4,38. Esse comportamento é particularmente relevante porque indica que o modelo não apenas identifica corretamente os erros com maior frequência, mas também entrega respostas percebidas como mais claras, adequadas e consistentes. O Claude Sonnet 4.6 mantém um patamar qualitativo próximo, com 4,46 em Zero-shot, 4,17 em Few-shot e 4,46 em Thought-Chain, o que reforça sua posição como um

modelo consistente, embora menos dominante que o GPT-5.4. O Gemini 3.1 Flash, por sua vez, apresenta um padrão interessante: parte de 4,08 em Zero-shot e melhora em prompts com maior riqueza de detalhes, alcançando 4,25 em Few-shot e 4,38 em Thought-Chain. Isso sugere que o modelo tende a se beneficiar de maior condução textual e de estratégias mais guiadas de raciocínio. Em contraste, o DeepSeek-V3.2 apresenta os menores valores em todas as técnicas, com 3,04 em Zero-shot, 2,92 em Few-shot e 2,88 em Thought-Chain, evidenciando não apenas baixo desempenho objetivo, mas também fragilidade na qualidade discursiva das respostas.

Para uma visão mais detalhada em relação a cada gráfico, a Figura 1 representa a taxa média de acerto de um modelo para um gráfico específico, permitindo observar não apenas quais VLMs obtiveram melhor desempenho, mas também quais itens se mostraram mais simples ou mais desafiadores ao longo do experimento. Como os gráficos foram organizados de acordo com o desempenho global, a figura estabelece uma gradação de dificuldade que facilita a comparação entre os casos mais facilmente reconhecidos e aqueles que impuseram maiores obstáculos aos modelos.

De modo geral, a Figura 1 mostra que o gráfico 2 se destaca como o caso mais facilmente identificado, apresentando valores elevados de acerto em praticamente todas as combinações de modelo e técnica. Em contraste, os gráficos 1 e 3 concentram os menores desempenhos do conjunto, o que sugere que os erros presentes nesses itens exigem um tipo de interpretação visual mais complexo, mais ambíguo ou dependente de um encadeamento de raciocínio que nem sempre é mantido de forma estável pelos modelos. Entre esses extremos, o gráfico 6 aparece como uma zona intermediária de dificuldade, produzindo resultados menos homogêneos e indicando que certos erros visuais não são imediatamente evidentes, embora também não representem os casos mais críticos do experimento.

A leitura comparativa entre os modelos também revela padrões relevantes. GPT-5.4 e Claude Sonnet 4.6 apresentam comportamento mais consistente ao longo das três técnicas, mantendo taxas de acerto elevadas em diferentes itens e demonstrando maior capacidade de adaptação a variações de prompt.

Esse padrão é particularmente visível em gráficos como 4, 7 e 8, nos quais ambos os modelos repetem desempenhos altos em mais de uma condição experimental. O Gemini 3.1 Flash, embora apresente bons resultados em alguns cenários, mostra maior oscilação entre os itens e entre as técnicas, sugerindo sensibilidade mais acentuada ao contexto da instrução. Já o DeepSeek-V3.2 concentra os menores valores do heatmap em diferentes pontos da matriz, evidenciando desempenho menos estável e maior dificuldade em sustentar interpretações corretas ao longo dos gráficos avaliados. Dessa forma, a Figura 1 reforça que a dificuldade dos itens não depende apenas

Tabela 3: Resultados comparativos dos modelos segundo acurácia e nota média.

Métrica	Execução/Prompt	GPT-5.4	Claude Sonnet 4.6	Gemini 3.1 Flash	DeepSeek-V3.2
Acurácia	Rodada 1	0,67	0,71	0,79	0,25
Acurácia	Rodada 2	0,92	0,79	0,58	0,29
Acurácia	Rodada 3	0,96	0,71	0,71	0,38
Nota	Zero-shot	4,71	4,46	4,08	3,04
Nota	Few-shot	4,38	4,17	4,25	2,92
Nota	Thought-Chain	4,63	4,46	4,38	2,88




Figura 1: Acurácia na identificação de erros por gráfico avaliado.




Figura 2: Qualidade das respostas em relação ao modelo e técnica de prompt.

do erro visual em si, mas também da capacidade de cada modelo em manter consistência interpretativa quando confrontado com diferentes tipos de gráfico e diferentes estratégias de prompt.

Em relação à qualidade das respostas, a Figura 2 mostra diversos insights importantes em relação aos oito gráficos. O caso mais estável do conjunto é o gráfico 2, que recebe nota 5 para GPT-5.4, Claude Sonnet 4.6, Gemini 3.1 Flash e DeepSeek-V3.2 independente de técnica de prompt, indicando que esse foi o item mais simples tanto para reconhecer o erro quanto para justificá-lo com clareza. Em contraste, os gráficos 1, 3 e 8 concentram as quedas mais visíveis de qualidade. O GPT-5.4 aparece como o modelo mais estável, com notas altas na maior parte dos itens e poucas oscilações relevantes. O Claude Sonnet 4.6 mantém bom desempenho geral, mas varia mais em pontos específicos. O Gemini 3.1 Flash ocupa uma posição intermediária, alternando respostas fortes e quedas localizadas conforme o item e a técnica. Já o DeepSeek-V3.2 reúne as menores notas do conjunto, com dificuldades mais persistentes especialmente nos gráficos 7 e 8, além de oscilações negativas nos gráficos 1, 3, 4 e 5. Assim, o heatmap da Figura 2 deixa claro que a identificação correta do erro não é o único elemento relevante: a forma como esse erro é explicado também varia consideravelmente entre modelos e itens.

A comparação entre a Figura 1, que mostra a acurácia, e a Figura 2, que mostra a nota, revela que o modelo com maior consistência entre desempenho objetivo e qualidade da resposta é o GPT-5.4. Nos itens em que sua acurácia é alta, como os gráficos 2, 4, 5, 7 e 8 em diferentes técnicas, a nota também tende a permanecer elevada, o que indica um alinhamento mais forte entre acertar o erro e explicá-lo bem. Mesmo quando não atinge a acurácia máxima, como no gráfico 1 e no gráfico 6, o modelo ainda preserva notas

altas, o que sugere boa capacidade de formular respostas úteis e bem estruturadas. O modelo que mais chama atenção pela divergência entre boa acurácia e nota mais instável é o Claude Sonnet 4.6. Em vários casos, o modelo identifica o erro com bom desempenho objetivo, especialmente nos gráficos 2, 4, 5, 6 e 7, mas sua qualidade textual oscila mais do que a do GPT-5.4, sobretudo nos gráficos 1, 3 e 8. O exemplo mais claro é o gráfico 8 em Few-shot, no qual o Claude mantém apenas acurácia 0,33 e recebe nota 1, revelando queda forte de qualidade, mas essa divergência também aparece em itens como o gráfico 3, em que a nota permanece baixa mesmo quando há algum nível de acerto. O Gemini 3.1 Flash mostra um comportamento intermediário, com alguns casos em que mesmo não identificando o erro, a qualidade das respostas eram boas, claras ou úteis, especialmente no Thought-Chain; já o DeepSeek-V3.2 tende a ter desempenho fraco nas duas métricas, embora em alguns itens ainda apresentem respostas com algum valor descritivo mesmo sem atingir o erro principal.

Quando se observam as técnicas de prompt, a análise qualitativa sugere que o Thought-Chain (CoT) é, no conjunto, a técnica mais forte na escala qualitativa, enquanto o Few-shot aparece como a mais frágil. O CoT tende a gerar respostas de melhor qualidade porque explicita um raciocínio em etapas, como identificar o tipo do gráfico, verificar os eixos, avaliar as cores e observar possíveis distorções. Esse efeito aparece de forma mais clara no Claude Sonnet 4.6 e no Gemini 3.1 Flash. No Claude, por exemplo, o CoT melhora de forma visível a qualidade nos gráficos 1 e 8, elevando a nota em relação ao Few-shot e tornando a resposta mais consistente. No Gemini, o CoT também se destaca nos gráficos 4, 5, 6, 7 e 8, onde as notas tendem a subir e a ficar mais uniformes. No GPT-5.4,

a diferença entre técnicas é menor, porque o modelo já mantém nível qualitativo alto mesmo em Zero-shot; ainda assim, o CoT preserva esse padrão elevado e se mostra a técnica mais segura em termos de estabilidade geral. O Few-shot, por outro lado, é a técnica que mais concentra quedas qualitativas, especialmente no Claude Sonnet 4.6 e no DeepSeek-V3.2. No Claude, isso fica muito evidente no gráfico 8, onde a nota cai para 1; no DeepSeek, o Few-shot acumula notas baixas em vários itens, como 1, 5, 7 e 8, sem converter o exemplo prévio em ganho consistente de qualidade. O Zero-shot ocupa uma posição intermediária: em alguns casos funciona muito bem, sobretudo para o GPT-5.4, mas não mantém a mesma regularidade qualitativa que o CoT nos modelos mais sensíveis à estrutura do prompt.

5.2 Desempenho dos VLMs na correção de erros

Na etapa de correção de erros, a Figura 3 e a Tabela 4 mostram um resultado bastante estável entre os dois VLMs avaliados. O GPT-5.4 alcança taxa média de acerto igual a 1,0 em Zero-shot, Few-shot e Thought-Chain (CoT), enquanto o Claude Sonnet 4.6 mantém 0,87 nas três técnicas. Isso indica que, para ambos os modelos, a mudança na formulação do prompt não altera o desempenho médio de correção, embora exista uma diferença clara de patamar entre eles. O principal insight, portanto, é que o GPT-5.4 se mostra mais consistente e mais preciso na etapa de correção, mantendo acerto total independentemente da técnica utilizada, enquanto o Claude Sonnet 4.6 apresenta um desempenho também estável, porém inferior. Nesse caso, não há evidência de que Zero-shot, Few-shot ou Thought-Chain tenham sido mais eficazes para melhorar a correção em qualquer um dos dois modelos, o que sugere que essa etapa depende mais da capacidade geral do VLM do que da estrutura específica do prompt.

Tabela 4: Acurácia das VLMs na correção de erros.

Tipo de Técnica	GPT-5.4	Claude Sonnet 4.6
Zero-shot	1,00	0,87
Few-shot	1,00	0,87
Thought-Chain	1,00	0,87




Figura 3: Qualidade das respostas na correção de erros.

Quando a Tabela 4 é comparada à análise da Tabela 3, especificamente na parte de acurácia, ainda considerando apenas GPT-5.4 e Claude Sonnet 4.6, percebe-se que a principal diferença entre as duas fases está na sensibilidade à técnica de prompt. Na identificação, o GPT-5.4 já apresentava desempenho superior e maior estabilidade qualitativa. O Claude Sonnet 4.6, por sua vez, mostrava um comportamento mais oscilante, indicando que a técnica com exemplos prévios não trouxe ganho qualitativo relevante. Na correção, contudo, essa variação desaparece: os dois modelos mantêm exatamente o mesmo resultado em todas as técnicas.

Em relação à qualidade das respostas, o contraste entre GPT-5.4 e Claude Sonnet 4.6 é mais divergente, assim como observado na Figura 3.

O heatmap da Figura 3 mostra que o GPT-5.4 mantém o padrão qualitativo mais estável na etapa de correção de erros. Em todas as três técnicas de prompt, o modelo apresenta notas máximas na maior parte dos itens, com a única redução recorrente concentrada no gráfico 4, no qual registra nota 4. O Claude Sonnet 4.6, por sua vez, também apresenta desempenho amplamente elevado e homogêneo, mas com maior limitação no gráfico 1, em que mantém nota 3 em Zero-shot, Few-shot e Thought-Chain, além de nota 4 no gráfico 3. Isso indica que, na correção, a diferença entre os modelos não está mais associada a oscilações entre técnicas, mas sim à consistência com que cada um sustenta respostas de alta qualidade nos diferentes itens. Em síntese, o principal insight é que o GPT-5.4 apresenta a melhor consistência geral na correção, enquanto o Claude Sonnet 4.6 também alcança desempenho forte, embora com fragilidades mais localizadas e persistentes em itens específicos.

Quando esse resultado é comparado à Tabela 3, que sintetiza a nota da identificação de erros, percebe-se que ambas as VLMs apresentam um comportamento ainda mais homogêneo na correção do que na etapa anterior. No caso do GPT-5.4, a correção preserva o bom desempenho já observado na identificação e o torna ainda mais uniforme entre os itens, reforçando a ideia de que, uma vez reconhecido o problema visual, o modelo tende a formular a solução com elevado grau de clareza e estabilidade. Na identificação, suas médias já eram altas em Zero-shot (4,71), Few-shot (4,38) e Thought-Chain (4,63); na correção, esse padrão se traduz em notas quase integralmente máximas, com apenas uma queda moderada no

gráfico 4. O Claude Sonnet 4.6, por sua vez, também já apresentava boa qualidade na identificação, com 4,46 em Zero-shot, 4,17 em Few-shot e 4,46 em Thought-Chain, mas na correção passa a exibir um comportamento mais uniforme entre as técnicas, concentrando suas limitações em poucos itens, especialmente no gráfico 1. Dessa forma, o novo resultado sugere que, na etapa de correção, a estrutura do prompt exerce influência bem menor sobre a qualidade final das respostas do que na identificação de erros, fazendo com que o desempenho dependa mais da capacidade do modelo em sustentar uma solução visual consistente.

6 CONCLUSÃO

Este trabalho teve como objetivo avaliar o desempenho de modelos multimodais na identificação e na correção de erros em visualizações de dados, considerando tanto a taxa de acerto quanto a qualidade das respostas produzidas. Para isso, foram conduzidas duas tarefas experimentais: na primeira, os modelos analisaram gráficos com erros de visualização; na segunda, propuseram correções para esses problemas. Em ambas as tarefas, foram comparadas diferentes técnicas de prompt, incluindo Zero-shot, Few-shot e Thought-Chain, de modo a investigar não apenas qual modelo apresentava melhor desempenho, mas também em que medida a formulação do prompt influenciava a clareza, a consistência e a utilidade analítica das respostas.

Na etapa de identificação de erros, os resultados revelaram maior variabilidade entre modelos, gráficos e técnicas de prompt, indicando que essa tarefa impõe maior complexidade interpretativa. Os achados mostraram que o desempenho dos modelos avaliados não depende apenas da arquitetura do modelo, mas também das características do gráfico avaliado e do tipo de instrução utilizada. Nesse cenário, o GPT-5.4 e o Claude Sonnet 4.6 apresentaram os melhores resultados gerais, enquanto os demais modelos demonstraram mais limitações em itens críticos. Além disso, a comparação entre acurácia e qualidade da resposta mostrou que identificar corretamente o erro não implica, necessariamente, explicá-lo com o mesmo nível de clareza e consistência, o que reforça a importância de avaliar essas duas dimensões de forma complementar. Em termos de prompt, a etapa de identificação mostrou que a técnica pode influenciar de maneira relevante os resultados, com destaque para o Thought-Chain, que em geral favoreceu respostas mais organizadas e qualitativamente mais consistentes, enquanto o Few-shot se mostrou mais instável e sem ganhos uniformes entre os modelos.

Na etapa de correção de erros, por sua vez, os resultados foram mais estáveis e consistentes, especialmente para o GPT-5.4 e o Claude Sonnet 4.6. Nessa fase, a influência das técnicas de prompt tornou-se pouco expressiva, sugerindo que, uma vez identificado o problema visual, a capacidade intrínseca do modelo passa a ter maior peso do que a estrutura da instrução. O GPT-5.4 destacou-se novamente por manter desempenho máximo e maior uniformidade entre as técnicas, enquanto o Claude Sonnet 4.6 também apresentou bom desempenho, embora em um patamar inferior. Assim, ao contrário do que se observou na identificação, a correção de erros não evidenciou uma técnica claramente superior, indicando que, nessa etapa, Zero-shot, Few-shot e Thought-Chain tendem a produzir resultados muito semelhantes.

Dessa forma, a articulação entre as duas etapas permite concluir que este estudo avançou além da simples mensuração de desempenho, ao examinar também a capacidade dos modelos de revisar, refinar e melhorar respostas em tarefas visuais. Em termos metodológicos, a etapa de identificação foi fundamental para mapear dificuldades, distinguir modelos mais consistentes e evidenciar a influência do prompt na interpretação dos erros. Já a etapa de correção mostrou que os modelos de melhor desempenho, sobretudo o GPT-5.4, apresentam maior potencial para apoiar atividades de revisão e aprimoramento de visualizações de dados. Em síntese, os resultados reforçam que a avaliação de modelos multimodais em contextos visuais deve considerar não apenas sua capacidade inicial de identificar problemas, mas também sua habilidade de justificar, revisar e propor melhorias de forma clara, consistente e analiticamente útil.

7 LIÇÕES APRENDIDAS

Ao longo do processo, foi possível obter um aprendizado significativo, sobretudo no que diz respeito à constatação de que a pesquisa científica demanda tempo, dedicação e rigor metodológico muito além do inicialmente previsto. Ademais, a maior parte do trabalho foi dedicada à avaliação manual das VLMs, sem automatização do processo. Essa escolha exigiu um número considerável de horas de estudo, mas possibilitou um exame mais detalhado e aprofundado do objeto de pesquisa, contribuindo para um domínio mais consistente sobre o tema investigado. Trata-se de uma experiência avaliada como bastante enriquecedora.

Foi possível, ainda, consolidar conhecimentos relevantes sobre metodologia científica, particularmente quanto à forma de estruturar e redigir uma pesquisa de modo a garantir sua reprodutibilidade. Dessa forma, os principais aprendizados concentraram-se no detalhamento da metodologia de escrita, na metodologia de pesquisa propriamente dita e na compreensão da complexidade inerente às VLMs que, uma vez desmistificadas, revelam-se processos que extrapolam a simples geração de respostas. Tais modelos envolvem uma série de requisitos técnicos ainda pouco compreendidos pela maior parte do público, não obstante o amplo usufruto de seus resultados.

Por fim, cabe destacar que as VLMs apresentam potencial expressivo; contudo, a ausência de uma base conceitual adequada para compreender seu funcionamento, seus mecanismos subjacentes e as fontes apropriadas de informação pode comprometer a obtenção dos melhores resultados. Nesse sentido, o processo também possibilitou o desenvolvimento da capacidade de diferenciar as respostas produzidas pelas principais inteligências artificiais atualmente disponíveis.

8 AGRADECIMENTOS

De todas as formas que mantêm uma pessoa viva e consciente, a palavra foi a que mais fez meu sangue pulsar.

Minha mãe Das Neves é a prova disso, pois com suas orações pôde manter meu coração batendo. Era para ela que eu pedia forças e energias nos meus piores dias. E foi para ela também que eu liguei quando tive minhas melhores notícias. Porque estar longe não significa estar distante. Portanto, é a ela que eu dedico a minha maior vitória.

Dedico também às minhas irmãs, que são as maiores inspirações de mulheres que eu poderia ter: empreendedoras, trabalhadoras e esforçadas, a cada passo dado, a cada conquista construída com esforço, dedicação e muita sabedoria. São elas: Deyse, Denise, Débora e Denifialra.

Não posso esquecer do meu pai, que me apoiou todas as vezes que precisei. Mesmo nem sempre presente fisicamente, se fez justo e compareceu sempre que eu precisava.

Minha moradia em Campina Grande-PB foi de grande aprendizado, pude compartilhar momentos e somar esforços, não poderia deixar de citar meus amigos: Afrânio, Guilherme, Gabriel, Luciano, Joyce, Davi e Amanda.

A caminhada foi muito complexa e poderia ter sido muito mais pesada sem as pessoas especiais com quem dividi o processo. Em especial, àqueles que estiveram a maior parte do tempo ao meu lado: Larissa Monique, Rafael Arruda, Luís Almeida e Davi Duarte.

Também tive boas amizades que não poderia deixar de citar: Iris, Thaís, Diego, Eduarda e João Vitor.

É impossível esquecer o tempo de Engenharia Química - dois longos anos que me marcaram profundamente - ao lado de Alice, Eduarda, Mary, Juan e Yohanna.

Ao longo dos estudos, do trabalho e da jornada, também pude fazer bons companheiros que me acompanharam nas madrugadas, nos fins de semana e nos dias em que o cansaço superaram o esforço. Nesses momentos, eu estava com essas pessoas fazendo qualquer coisa que me fizesse bem: Deep, Maisena, Pauducco, Kayan e a galera do Discord.

Sou feliz e contente por ter amizades que ultrapassaram o tempo e a distância, presentes na energia de me desejar uma boa caminhada. O pessoal de Araripina-PE - meus amigos de longa data - sintam-se privilegiados, pois eu não seria mais feliz se não pudesse dividir uma vitória com vocês. Entre eles: Alisson, Arthur, Laila, Erycles e Amanda.

Não menos importante, sou muito grato aos Professores de Computação, em especial a Livia Sampaio que fez da minha experiência no PET um momento marcante e mais que especial, ao meu orientador Maxwell Guimarães, que sempre foi solícito, organizado e me mostrou que com amor ao que faz, os resultados podem ser melhores, esse professor me deu uma esperança na graduação de que o meu aprendizado poderia fazer a diferença na vida das pessoas.

A todas as pessoas especiais não citadas aqui, mas que foram importantes em algum momento do processo: muito obrigado.

Por fim, quero agradecer a mim mesmo. Por mais que em diversos momentos eu estivesse sozinho, fui a minha melhor companhia e o meu maior incentivo. Minhas escolhas foram as maiores aliadas ao meu desejo de vencer, de ser grande, de ser realizado - e de conquistar aquilo que, em 2014, eu prometi a mim mesmo que conquistaria. Eu sou a minha maior inspiração.

E sou grato a Deus por ter chegado tão longe, sabendo que ainda há um longo caminho pela frente.

Referências

- [1] LAN, X.; LIU, Y. "I came across a junk": Understanding design flaws of data visualization from the public's perspective. *IEEE Transactions on Visualization and Computer Graphics*, v. 31, n. 1, p. 393–403, 2025.
- [2] VÁZQUEZ, P.-P. Are LLMs ready for visualization? In: *IEEE 17th Pacific Visualization Conference (PacificVis)*, 2024, IEEE, p. 343–352.
- [3] BENDECK, A.; STASKO, J. An empirical evaluation of the GPT-4 multimodal language model on visualization literacy tasks. *IEEE Transactions on Visualization and Computer Graphics*, v. 31, n. 1, p. 1105–1115, jan. 2025.
- [4] KHAN, S. R.; CHANDAK, V.; MUKHERJEA, S. Evaluating LLMs for visualization generation and understanding. *Discover Data*, v. 3, n. 15, 2025. <https://doi.org/10.1007/s44248-025-00036-4>
- [5] BONÁS, V.; SINNONA, M.; SILESS, V.; IARUSSI, E. De-rendering, reasoning, and repairing charts with vision-language models. *arXiv:2602.20291*, 2026.
- [6] ALAYRAC, J.-B. et al. Flamingo: a visual language model for few-shot learning. In: *Advances in Neural Information Processing Systems*, v. 35, p. 23716–23736, 2022.
- [7] LI, Yiqiao; WEI, Jie; KAMGA, Camille. Investigating Vision-Language Model for Point Cloud-based Vehicle Classification. *arXiv preprint arXiv:2504.08154*, 2025. Disponível em: <https://arxiv.org/pdf/2504.08154>. Acesso em: 17 jul. 2026. .
- [8] WU, Tao et al. Semantic Alignment for Multimodal Large Language Models. *arXiv preprint arXiv:2408.12867*, 2024. Disponível em: <https://arxiv.org/abs/2408.12867>. Acesso em: 17 jul. 2026.
- [9] VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems (NeurIPS)*, v. 30, p. 5998–6008, 2017.
- [10] KUMAR, P. Large language models (LLMs): survey, technical frameworks, and future challenges. *Artificial Intelligence Review*, v. 57, n. 10, p. 260, ago. 2024.
- [11] BROWN, T. B. et al. Language models are few-shot learners. In: *Advances in Neural Information Processing Systems (NeurIPS)*, v. 33, p. 1877–1901, 2020.
- [12] MINAEI, S. et al. Large language models: a survey. *arXiv preprint arXiv:2402.06196*, 2024.
- [13] PROMPT ENGINEERING GUIDE. Prompt engineering guide. Disponível em: <https://www.promptingguide.ai>. Acesso em: 27 de Abril de 2026. .
- [14] WEI, J. et al. Chain-of-thought prompting elicits reasoning in large language models. In: *Advances in Neural Information Processing Systems (NeurIPS)*, v. 35, p. 24824–24837, 2022.
- [15] SHI, Freda et al. Language Models are Multilingual Chain-of-Thought Reasoners. In: *International Conference on Learning Representations (ICLR)*, 2023. Disponível em: <https://arxiv.org/abs/2210.03057>. Acesso em: 24 de Maio de 2026. .
- [16] WILKE, C. *Fundamentals of data visualization: a primer on making informative and compelling figures*. Sebastopol: O'Reilly Media, 2019.
- [17] HEHMAN, E.; XIE, S. Y. Doing better data visualization. *Advances in Methods and Practices in Psychological Science*, v. 4, n. 4, p. 1–18, 2021.
- [18] MIDWAY, S. R. Principles of effective data visualization. *Patterns*, v. 1, n. 9, p. 100141, 2020.
- [19] NGUYEN, V. T.; JUNG, K.; GUPTA, V. Examining data visualization pitfalls in scientific publications. *Visual Computing for Industry, Biomedicine, and Art*, v. 4, n. 1, p. 27, out. 2021. <https://doi.org/10.1186/s42492-021-00092-y>

- [20] KNAFLIC, C. N. Storytelling com dados: um guia sobre visualização de dados para profissionais de negócios. Rio de Janeiro: Alta Books, 2019.
- [21] MATARAZZO, A.; TORLONE, R. A Survey on Large Language Models with some Insights on their Capabilities and Limitations. arXiv preprint arXiv:2501.04040, 2025.
- [22] DANISH, S.; SADEGHI-NIARAKI, A.; KHAN, S. U.; DANG, L. M.; TIGHTIZ, L.; MOON, H. A comprehensive survey of Vision-Language Models: Pretrained models, fine-tuning, prompt engineering, adapters, and benchmark datasets. *Information Fusion*, v. 126, Part B, p. 103623, 2026.
- [23] ANTHROPIC. Claude Sonnet 4.6 System Card. 2026. Disponível em: <https://www.anthropic.com/claude-sonnet-4-6-system-card>. Acesso em: 17 jul. 2026.
- [24] OPENAI. Introducing GPT-5.4. 2026. Disponível em: <https://openai.com/index/introducing-gpt-5-4/>. Acesso em: 17 jul. 2026.
- [25] GOOGLE DEEPMIND. Gemini 3.1 Flash Image - Model Card. 2026. Disponível em: <https://deepmind.google/models/model-cards/gemini-3-1-flash-image/>. Acesso em: 17 jul. 2026.
- [26] WILKINSON, Mark D. et al. The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*, v. 3, n. 160018, 2016. Disponível em: <https://doi.org/10.1038/sdata.2016.18>. Acesso em: 18 jul. 2026.
- [27] SILVA et al. Combining TSL and LLM to Automate REST API Testing: A Comparative Study (arXiv, 2025). Disponível em: <https://arxiv.org/pdf/2509.05540>. Acesso em: 18 jul. 2026.
- [28] MAMBOU, E. N.; ESENOGHO, E. A Comparative Analysis of Leading AI Chatbots: Benchmarking ChatGPT, DeepSeek, Gemini, Grok, and Claude AI. *ResearchGate*, 2025.
- [29] Zhao, W. X. et al. Understanding LLMs: A Comprehensive Overview from Training to Inference. arXiv, 2024. Disponível em: <https://arxiv.org/pdf/2401.02038>. Acesso em: 18 jul. 2026.
- [30] DEEPSEEK-AI. DeepSeek-V3.2. Hugging Face, 2025. Disponível em: <https://huggingface.co/deepseek-ai/DeepSeek-V3.2>. Acesso em: 22 jul. 2026.
- [31] DATASTUDIOS. DeepSeek: What File Types Can Be Uploaded and How They Are Processed. 30 set. 2025. Disponível em: <https://www.datastudios.org/post/deepseek-what-file-types-can-be-uploaded-and-how-they-are-processed>. Acesso em: 22 jul. 2026.