

Avaliação do uso de LLMs na melhoria de visualização de dados com base em boas práticas da literatura

Denilson Deivid Lima Silva

denilson.silva@ccc.ufcg.edu.br

Universidade Federal de Campina Grande (UFCG)
Campina Grande, Paraíba, Brasil

Maxwell Guimarães de Oliveira

maxwell@ccc.ufcg.edu.br

Universidade Federal de Campina Grande (UFCG)
Campina Grande, Paraíba, Brasil

RESUMO

A qualidade das visualizações de dados é determinante para a comunicação científica e a tomada de decisão. Com o avanço dos modelos de linguagem de grande escala (LLMs) e dos modelos de visão-linguagem (VLMs), surge a oportunidade de investigar se essas ferramentas são capazes de identificar e corrigir erros em visualizações gráficas com base em boas práticas da literatura. Este trabalho avalia o desempenho de quatro LLMs: ChatGPT, Claude, Gemini e DeepSeek. Sendo realizado em duas etapas: identificação de erros visuais em 8 gráficos e geração de versões corrigidas. Foram aplicadas três técnicas de prompt (zero-shot, few-shot e chain-of-thought) em três rodadas independentes, totalizando 288 análises, avaliadas por indicador binário de acerto e escala Likert. Os resultados indicam que ChatGPT e Claude se destacaram como os modelos mais robustos, enquanto o DeepSeek apresentou desempenho consistentemente inferior, inclusive com respostas alucinatórias. Na etapa de correção, ambos os modelos selecionados obtiveram alto desempenho, com o ChatGPT demonstrando maior consistência qualitativa. Conclui-se que LLMs possuem potencial relevante para análise e melhoria de visualizações de dados, embora limitações específicas por modelo e por tipo de gráfico ainda demandem investigação aprofundada.

1 INTRODUÇÃO

A qualidade das visualizações de dados possuem grande relevância na comunicação científica e na tomada de decisão em áreas como jornalismo, estatística e análise de dados. Gráficos mal construídos são capazes de induzir ao erro e interpretações errôneas, mesmo que em partes subjacentes da visualização estejam corretas [1]. Paralelamente, temos a expansão dos modelos de linguagem de grande escala (LLMs) e dos modelos de visão-linguagem (VLMs), que possuem capacidade para interpretação automática de uma visualização de dados, dessa maneira, motivando investigações sobre o quanto

tais ferramentas podem analisar falhas em representações gráficas com base em critérios bem definidos da literatura.

Nesse quesito, Vázquez [2], descreve questionamentos sobre o quanto as LLMs estariam prontas para tarefas de visualização, destacando que mesmo tendo resultados promissores em contextos simples, os modelos possuem barreiras consideráveis em contexto que exigem raciocínio visual mais profundo. De modo semelhante, Bendeck & Stasko [3] consideraram estudos empíricos sobre o GPT-4 em tarefas de literacia visual, compreendendo que o modelo conquistou desempenho equivalente ao percentil 16 em comparação a humanos. Com isso, reforçando a comprovação que as LLMs possuem desafios nas estruturas de leitura e interpretação gráfica.

Diante desse cenário, este trabalho tem como objetivo avaliar se as LLMs são capazes de identificar erros clássicos de visualização de dados com base nas boas práticas descritas na literatura, em especial nas diretrizes de Claus Wilke e Cole Knaflic. Adicionalmente, verificar se esses modelos conseguem corrigir tais erros gerando novas visualizações sem introduzir novos problemas gráficos.

Para alcançar esse objetivo, foram avaliados quatro modelos de linguagem: ChatGPT, Claude, Gemini e DeepSeek. Sendo submetidos a um conjunto de 8 gráficos com erros visuais documentados. A avaliação foi estruturada em duas etapas: a identificação dos erros e a geração de versões corrigidas. Em ambas, foram aplicadas três técnicas de prompt distintas: zero-shot, few-shot e chain-of-thought. Dessa forma, foram realizadas três rodadas independentes, totalizando 288 análises. O desempenho foi mensurado por meio de um indicador binário de acerto e de uma escala Likert de cinco pontos, que avaliou a qualidade percebida das respostas.

As principais contribuições deste estudo consistem em: (i) uma metodologia sistemática e reprodutível para avaliação de LLMs em tarefas de análise visual, fundamentada em princípios teóricos consolidados; (ii) uma

comparação empírica entre quatro modelos de linguagem e três técnicas de prompt, evidenciando que a técnica mais eficaz varia de acordo com o modelo utilizado; e (iii) a constatação de que as LLMs apresentam potencial relevante tanto para identificação quanto para correção de erros em visualizações de dados, com desempenho superior observado no ChatGPT e no Claude.

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta os trabalhos relacionados, contextualizando as abordagens existentes na literatura sobre o uso de LLMs e VLMs em tarefas de visualização; a Seção 3 expõe a fundamentação teórica, abordando os conceitos de LLMs, modelos de visão-linguagem, engenharia de prompt e boas práticas em visualização de dados; a Seção 4 descreve o método adotado, detalhando as etapas de avaliação, os prompts utilizados e os critérios de análise; a Seção 5 apresenta e discute os resultados obtidos nas duas etapas do estudo; e a Seção 6 traz as conclusões e sugestões para trabalhos futuros.

2 TRABALHOS RELACIONADOS

Nesta seção, serão apresentados os trabalhos ligados diretamente ao tema principal deste estudo, eles tem objetivo de contextualizar e demonstrar abordagens existentes na literatura. São discutidos dois estudos principais, ambos focando na investigação do uso de modelos de linguagem e modelos multimodais na análise e melhoria de visualização de dados, destacando suas contribuições, limitações e diferenças em relação à proposta deste trabalho.

2.1 Evaluating LLMs for Visualization Generation and Understanding

No estudo de Khan et al. [4], o foco está no potencial de modelos de linguagem de grande escala (LLMs) em tarefas que extrapolam a geração textual, incluindo a interpretação e produção de visualizações de dados. O trabalho propõe uma avaliação sistemática da capacidade desses modelos em duas vertentes: geração de visualizações partindo de descrições textuais e interpretação de gráficos com base em informações visuais e semânticas.

De forma metódica, o estudo adota tarefas que envolvem uma gama de gráficos (pizza, barras, linhas e dispersão), sendo avaliados sob diversos critérios como de corretude, coerência e fidelidade.

Como resultado, embora as LLMs apresentem bom desempenho em tarefas simples e estruturadas, a sua resposta decai nitidamente quando os cenários exigem uma maior capacidade de raciocínio visual e interpretação contextual. Pode-se observar que os modelos cometem erros na leitura de relações quantitativas e na identificação

de inconsistências visuais, discretizando o fenômeno de alfabetização visual.

Mesmo com uma análise detalhada, o estudo evidencia uma proporção geral, não abordando de forma específica a identificação de erros em gráficos com base em princípios teóricos consolidados de design. Nesse sentido, o presente estudo se diferencia ao focar na detecção de falhas na visualização de dados fundamentada em boas práticas da literatura, especificamente nas diretrizes descritas por Claus Wilke, além de incorporar uma avaliação estruturada do desempenho desses modelos.

2.2 De-rendering, Reasoning and Repairing Charts with Vision-Language Models

Com o avanço dos modelos multimodais, especialmente os de modelos de visão-linguagem, temos uma nova abordagem para a análise automática de visualização de dados. O trabalho de Larussi et al.[5] De-rendering, Reasoning, and Repairing Charts with Vision-Language Models trata sobre um pipeline estruturado para interpretação, diagnóstico e correção de diversos gráficos, utilizando modelos que integram informações visuais e textuais.

A proposta do autor consiste numa extração subjacente da visualização, o que inclui eixos, legendas e variáveis presentes no gráfico. A partir disso, o modelo utilizado tem o objetivo de encontrar inconsistências ou inadequações nos gráficos. Por fim, o modelo ainda é orientado a realizar uma melhoria na imagem, focando em pontos como clareza, precisão e efetividade comunicativa.

O estudo pode demonstrar que VLMs são capazes de realizar tarefas complexas de interpretação visual, além de identificar o tipo de gráfico mais adequado. No entanto, ainda é verídico que tal capacidade ainda está sob limitados fatores, como ambiguidade semântica, erros de inferência e dependência da qualidade da análise inicial.

Dessa maneira, o presente estudo em questão se diferencia ao adotar uma abordagem avaliativa sistemática com base na literatura, além de ter princípios teóricos bem definidos. Porém, não é orientado a um pipeline, como no trabalho de Larussi et al.(2026), o que pode gerar novos resultados.

3 FUNDAMENTAÇÃO TEÓRICA


Para uma análise de visualização de dados utilizando LLMs, este trabalho fundamenta-se em tópicos ligados diretamente ao tema, com foco em aparatos bibliográficos mais recentes. No mais, esta seção está estruturada nos seguintes tópicos: boas práticas em visualização de dados; modelos de linguagem de grande escala e conceitos sobre engenharia de prompt.

3.1 Modelos de Linguagem de Grande Escala (LLMs)

Os modelos de linguagem de grande escala (LLMs) representam um marco significativo na área de inteligência artificial (IA), tendo como um destaque a arquitetura transformer. Esses modelos são treinados a partir de enormes volumes de dados textuais e possuem bilhões de parâmetros, dando à tecnologia da IA o poder de realizar tarefas complexas, como geração de texto, tradução e análise de dados.

A arquitetura transformer foi proposta por Ashish Vaswani et al. [9], ela revolucionou o processamento de linguagem natural (PLN) ao substituir a abordagem recorrente por mecanismo baseado em atenção. Diferente dos modelos anteriores, como redes neurais recorrentes (RNNs), o transformer processa os dados de forma paralela, permitindo maior eficiência computacional e na melhoria da captura de dependências de longo alcance em sequências textuais. Dessa forma, podemos visualizar através da figura 1 a estrutura geral da arquitetura transformer, bem como seus principais componentes.

Figura 1: Arquitetura transformer. Fonte:[1].



O principal componente desse sistema é o mecanismo de autoatenção (self-attention), ele permite atribuir diferentes pesos às palavras de uma sequência e compreender quais palavras têm maior importância dentro do contexto. Além disso, outra característica importante é

sua composição em camadas de atenção e redes neurais feedforward, que são divididas em dois blocos essenciais para seu funcionamento, o codificador (encoder) e o decodificador (decoder), sendo estas responsáveis pela representação e geração de sequências.

A partir dessa arquitetura, temos uma evolução nas LLMs, que ampliam as escalas do modelo tanto em dados quanto em parâmetros. De acordo com Kumar [10], as LLMs têm sido aplicadas em diversas áreas, dentre elas, processamento de linguagem natural, medicina, educação e principalmente a generalização de código, demonstrando uma grande capacidade de generalização.

No contexto de aprendizagem de máquina, a generalização está ligada à capacidade de um modelo de adquirir um conhecimento durante seu treinamento sobre dados não vistos. Conforme Tom B. Brown et al. [11], LLMs são capazes de realizar tarefas em regime de pouca informação, evidenciando sua habilidade de generalizar para novos contextos com mínima adaptação.

Além disso, Minaee et al. [12] cita que o desempenho desses modelos está proporcionalmente relacionado a escala, sobre o que são chamadas de scaling laws, nas quais os modelos maiores apresentam um melhor desempenho.

3.1.1 Modelos de Visão-Linguagem (VLMs)

Os modelos multimodais, conhecidos como Vision-Language Models (VLMs), representam uma evolução nas LLMs ao integrarem informações textuais e visuais em apenas um sistema [6]. Esses modelos realizam interpretação de imagens e linguagem natural, como descrição de cenas, análise de gráficos e respostas baseadas em imagens. Alec Radford et al. [7] cita que modelos como o CLIP demonstram a eficácia do aprendizado conjunto entre texto e imagem. Embora os VLMs tenham evoluído significativamente, problemas associados ao alinhamento multimodal e à equivalência semântica entre tokens visuais e linguísticos ainda representam limitações importantes para a compreensão contextual e inferência semântica desses modelos [8].

3.2 Engenharia de Prompt

A engenharia de prompt trata-se do processo de criação e otimização do texto/recurso utilizado nos modelos de linguagem, com o objetivo de aumentar a qualidade e precisão de suas respostas. De acordo com o Prompt Engineering Guide [13], a forma como o prompt é estruturado influencia de forma direta o resultado da resposta do modelo, sendo um fator determinante para tarefas de raciocínio e interpretação.

Entre as técnicas utilizadas, podemos destacar o zero-shot prompting, em que o modelo realiza uma tarefa sem exemplos prévios, utilizando apenas dos dados de

treinamento e sua capacidade de generalização. Já o few-shot prompting consiste na inclusão de exemplos no prompt, seja por texto ou imagem, permitindo ao modelo compreender padrões e melhorar sua resposta. Por fim, a técnica chain-of-thought (CoT), proposta por Wei et al. [14], estabelece etapas de raciocínio, incentiva o modelo a executar um passo a passo e tal recurso pode aumentar significativamente a capacidade do modelo de resolver problemas complexos.

No mais, estudos [15] indicam que a escolha da técnica de prompt impacta diretamente no desempenho dos modelos, especialmente nas tarefas que envolvem análise estruturada de dados e inferência textual.

3.3 Visualização de Dados e Boas Práticas

A visualização de dados tem o objetivo de representar informações graficamente, comunicando padrões e apoiando na tomada de decisão. De acordo com Claus Wilke [16], visualizações eficazes devem priorizar clareza, precisão e foco na mensagem principal. Estudos de Hehman & Xie [17] citam que a escolha adequada da representação visual influencia diretamente na compreensão dos dados. Nesse tópico, a literatura destaca que erros no design são comuns e também podem comprometer a interpretação das informações [18].

Os principais fundamentos estão baseados na seleção adequada do tipo de gráfico, uso correto de escalas e redução de elementos desnecessários, assim, melhorando a comunicação gráfica. Ademais, recomendações recentes enfatizam o uso de cores apropriadas e visualizações que melhor expressem relações e distribuições [17].

Erros comuns como truncamentos de eixo, uso errôneo de cores e sobrecarga visual são amplamente documentados e podem atrapalhar no entendimento da informação. Esses princípios são amplamente abordados na literatura recente, especificamente os que analisam falhas comuns em visualizações científicas [19].

Dessa maneira, a adoção de boas práticas, conforme destacado por Claus Wilke [16], torna-se crucial em qualquer visualização que preza por qualidade e clareza.

4 MÉTODO

Para conseguir alcançar os objetivos deste estudo, foram estruturadas duas partes principais: (i) focada em analisar se as LLMs conseguem identificar os erros de visualização com base em boas práticas da literatura e (ii) focada em analisar se as LLMs conseguem corrigir os gráficos sem inserir novos erros.

4.1 Etapa (i) identificação dos erros

Como pressuposto de análise, foram escolhidos 8 (oito) gráficos com problemas clássicos de visualização. Os erros

encontrados foram documentados em tabela de mapeamento contendo: número sequencial, localização da figura de inspiração, tipo de gráfico analisado, descrição detalhada do erro e sugestão de correção. Além disso, para melhor representar os erros, foram criados 8 gráficos originais baseados nos mesmos princípios e contextos das visualizações analisadas dos livros em questão, representando os mesmos erros mas com dados e contextos distintos.

Na etapa (i) de avaliação de identificação do erro gráfico, foi construída uma planilha de mapeamento para registrar, de forma padronizada, o desempenho de diferentes LLMs na interpretação de respostas a um conjunto dos 8 gráficos. A planilha foi estruturada em um arranjo fatorial, combinando: (i) quadro modelos de linguagem (ChatGPT, Claude, Gemini e DeepSeek), (ii) três estratégias de prompt (Zero-shot, Few-shot e Thought-Chain) e (iii) três rodadas independentes de teste, mantendo os mesmos oito itens de gráfico (1 a 8) em todas as condições. Para cada combinação LLM x Estratégia x Rodada x Gráfico, foram registrados dois indicadores: um indicador binário de acerto (ACERTO), codificado como 1 para resposta correta e 0 para resposta incorreta, e uma nota Likert (LIKERT) de 1 a 5, utilizada para mensurar a qualidade percebida da resposta (por exemplo, clareza, adequação e completude), independentemente do acerto. Dessa maneira, temos uma pesquisa constituída por um total de 288 análises: contendo 96 por rodada e 32 por técnica de prompt. A justificativa da realização de 3 rodadas (com 96 análises cada) se dá pela importância de confirmar a consistência dos dados e mostrar que eles não possuíam variação significativa entre as rodadas, validando a confiabilidade das respostas.

Para a validação dos erros nos gráficos (parte (i)), utilizaram-se três técnicas de prompt: zero-shot, few-shot e Thought Chain (Tabela 1). Essas técnicas foram selecionadas para compreender através de diferentes estratégias de estímulo como elas influenciam na análise dos erros visuais. É importante ressaltar que, independente da técnica utilizada, nenhum dos exemplos empregados nos prompts foi inserido um erro específico que coincidissem com os erros presentes nos 8 gráficos de avaliação, de forma a testar a capacidade de generalização dos modelos em identificar problemas visuais não previamente exemplificados.

Tabela 1 - Especificação das técnicas para identificação de erros

Tipo de Técnica	Prompt criado	Tipo de mecanismo
zero-shot	Analise o gráfico	O modelo não

	apresentado e identifique se há erros de visualização. Explique se houver erros.	recebe exemplos anteriores ou contexto, deve-se basear no conhecimento pré treinado.
few-shot	Gráfico: o gráfico de barras apresenta o eixo X começando em 5 enquanto o Y inicia em 0 Resposta: o gráfico apresenta um erro de escala, pois o eixo X deve começar em zero para que não haja distorção da percepção dos dados. Dessa forma, analise o gráfico apresentado e identifique se há erros de visualização. Explique se houver erros.	O modelo recebe um exemplo para se orientar em tom e nível de simplicidade esperada.
Thought Chain Prompt (CoT)	1-identifique o tipo do gráfico 2-verifique os eixos 3-avalie as cores 4-verifique distorções Com base nesse passo a passo, identifique se há erros no gráfico e realize uma explicação.	O modelo é incentivado a pensar num passo a passo e dividir a explicação em passos lógicos.

Para a parte da análise de respostas geradas, foi adotada uma escala Likert de cinco pontos. A escala foi definida da seguinte forma: nota 5 - o modelo identifica o erro-alvo, apresenta justificativa correta e apresenta novas formas de melhoria na visualização; nota 4 - o modelo identifica o erro-alvo, mas apresenta falhas na explicação; nota 3 - o modelo não identifica o erro-alvo, mas apresenta uma análise útil e valiosa em relação ao gráfico; nota 2 - o modelo não identifica o erro-alvo e apresenta uma análise fraca; nota 1- o modelo não identifica o erro-alvo e não apresenta uma análise irrelevante ou fora de contexto.

4.2 Etapa (ii) geração dos gráficos corrigidos

Nesta etapa de correção de erro, segue o mesmo pressuposto da parte (i), porém com escopo reduzido. Realizou-se uma única rodada de testes avaliando os mesmos 8 gráficos, utilizando apenas 2 LLMs, que apresentaram melhor desempenho na etapa anterior. No mais, esta etapa também compreende uma tabela com a especificação dos prompts utilizados (Tabela 2), aplicando as três técnicas de prompt (zero-shot, few-shot e Thought

Chain), e uma escala Likert para validação da qualidade dos gráficos corrigidos gerados pelos modelos.

Tabela 2 - Especificação das técnicas para geração de gráficos corrigidos

Tipo de Técnica	Prompt criado	Tipo de mecanismo
zero-shot	Analise o gráfico apresentado e identifique o erro de visualização. Em seguida, crie um novo gráfico que corrija este erro sem introduzir novos problemas visuais	O modelo não recebe exemplos anteriores ou contexto, deve-se basear no conhecimento pré treinado.
few-shot	Gráfico: o gráfico de barras apresenta o eixo X começando em 5 enquanto o Y inicia em 0 Resposta: o gráfico apresenta um erro de escala, pois o eixo X deve começar em zero para que não haja distorção da percepção dos dados. Dessa forma, analise o gráfico apresentado e identifique o erro e crie um novo gráfico que corrija o problema.	O modelo recebe um exemplo para se orientar em tom e nível de simplicidade esperada.
Thought Chain Prompt (CoT)	1-Identifique o tipo do gráfico. 2-Verifique os eixos e cores. 3-Analise distorções. 4-Crie um novo gráfico corrigindo o erro identificado.	O modelo é incentivado a pensar num passo a passo e dividir a explicação em passos lógicos.

Na análise da qualidade das respostas produzidas (gráficos corrigidos), foi adotada uma segunda escala likert também com cinco pontos, seguindo a mesma estratégia de pontuação da etapa anterior. A escala foi definida da seguinte forma: nota 5 - o modelo gera um gráfico corrigido, removendo completamente o erro-alvo sem introduzir novos erros visuais; nota 4 - o modelo gera um gráfico corrigido, mas com pequenas falhas visuais ou imprecisões; nota 3 - o modelo tenta corrigir o erro, mas o resultado fica parcialmente correto ou incompleto; nota 2 - o modelo não consegue corrigir adequadamente o erro e introduz novos problemas visuais; nota 1 - o modelo não

consegue gerar um gráfico relevante ou sua resposta fica fora de contexto.

4.3 Ferramentas e Softwares utilizados

Para a criação dos 8 gráficos originais, utilizou-se o software Canva, onde cada gráfico foi desenvolvido manualmente do zero, inspirando-se nos mesmos erros visuais identificados nos gráficos de referência extraídos dos livros Fundamentos da Visualização (Claus Wilke) e Storytelling com Dados (Cole Knaflitz). No que tange os modelos de linguagens, os utilizados foram: ChatGPT versão 5.4, Claude versão Sonnet 4.6, Gemini versão rápida e Deepseek versão 3.2. Para otimizar o processo de avaliação dos modelos, considerando as limitações de recursos do ChatGPT (que teria demandado tempo excessivo para identificação de erros e geração de gráficos), foi utilizado o software Trae com a versão GPT-4 5.4 integrada, permitindo maior eficiência na validação e análise das respostas dentro do cronograma de pesquisa.

4.4 Critério de análise e avaliação das respostas

A avaliação das respostas foi realizada manualmente em ambas as etapas do estudo. Na etapa (i) de identificação de erros, avaliou-se: (a) acurácia na identificação do erro-alvo, classificada como acerto (1) ou erro (0), e (b) qualidade geral da resposta através da escala Likert de cinco pontos. Na etapa (ii) de geração de gráficos corrigidos, avaliou-se: (a) capacidade do modelo em gerar um novo gráfico que removesse o erro identificado, e (b) presença de novos erros visuais introduzidos durante a geração, também quantificada pela escala Likert. Esta abordagem manual garantiu avaliação contextual e interpretação precisa das respostas, considerando nuances que métricas automáticas poderiam não capturar.

4.5 Reprodutibilidade e transparência metodológica

Esta pesquisa foi estruturada com princípios de reprodutibilidade e transparência, alinhando-se com diretrizes de ciência aberta e boas práticas de pesquisa. Todos os seus componentes foram documentados de forma explícita e detalhada: (i) seleção e características dos 8 gráficos analisados, com inspiração em referências teóricas consolidadas [16, 20], (ii) especificação completa das três técnicas de prompt utilizadas em ambas as etapas (Tabelas 1 e 2), (iii) definição clara das escalas Likert para identificação de erros e geração de gráficos corrigidos, (iv) identificação precisa das versões dos modelos avaliados (ChatGPT 5.4, Claude Sonnet 4.6, Gemini rápida e Deepseek 3.2), (v) descrição detalhada do procedimento de

avaliação manual em ambas as etapas, e (vi) ferramentas utilizadas para criação e análise (Canva e Trae).

Além disso, todas as respostas geradas pelos modelos foram registradas e documentadas integralmente, incluindo: (a) respostas da etapa (i) referentes à identificação de erros e justificativas dos modelos, e (b) gráficos corrigidos gerados na etapa (ii). Estes dados foram organizados em repositório digital acessível e encontram-se disponibilizados em plataforma de armazenamento em nuvem (Google Drive), permitindo que pesquisadores, revisores e leitores possam acessar, verificar e replicar integralmente o estudo. O link de acesso ao repositório de dados é fornecido no Apêndice A deste trabalho.

Esta documentação abrangente permite que qualquer pesquisador replique integralmente o estudo sob as mesmas condições, verifique os resultados, conduza análises comparativas independentes ou estenda a investigação com modelos diferentes, garantindo a integridade e confiabilidade dos achados.

4.6 Limitações do estudo


Este estudo apresenta algumas limitações que devem ser consideradas. Primeiramente, a amostra de LLMs avaliadas é limitada a quatro modelos (ChatGPT 5.4, Claude Sonnet 4.6, Gemini Rápida e Deepseek 3.2), não representando a totalidade de modelos disponíveis no mercado. Além disso, a etapa (ii) de geração de gráficos foi conduzida com apenas uma rodada de testes, reduzindo o escopo comparativo em relação à etapa anterior. A avaliação manual, embora garanta interpretação contextual, pode estar sujeita ao viés do avaliador.

5 ANÁLISE E DISCUSSÃO DE RESULTADOS

5.1 Desempenho das LLMs na identificação de erros

A análise de 288 casos proporcionou diversos insights sobre as LLMs, principalmente em relação a sua evolução com a repetição dos erros de visualização, mostrando que todas tem um grande potencial de generalização e aprendizado contínuo a partir da repetição de imagens somadas a um contexto. Dessa maneira, podemos explorar as principais reflexões de acordo com as análises a seguir.


Figura 2: Desempenho das LLMs - taxa de acerto médio.



Análise: este gráfico sintetiza o desempenho consolidado: para cada técnica, temos a taxa de acerto médio de cada LLM agregado das rodadas e dos 8 gráficos. Ele representa uma visualização de decisão, pois ele responde diretamente qual técnica responde melhor para cada LLM, além de demonstrar qual se mantém melhor independente da técnica que, nesse caso, é o ChatGPT. Dessa maneira, temos um ranking global consistente, sendo ele de forma decrescente: ChatGPT, Claude, Gemini e DeepSeek. No mais, podemos detalhar as seguintes características:

- **ChatGPT:** tem melhor desempenho no Zero-shot e Thought-Chain (0,875) e uma queda no few-shot (0,792). Isso sugere que os exemplos utilizados no Few-shot podem não ter ajudado na análise (ou até mesmo enviesando), enquanto o encadeamento de raciocínio (Thought-Chain) preservou a performance do Zero-shot.
- **Claude:** se mantém em 0,75 em Zero-shot e Thought-Chain, com leve queda em Few-shot (0,708). Indicando que o modelo é forte de forma robusta, mas não necessariamente beneficia do Few-shot aplicado.
- **Gemini:** melhora do Zero-shot (0,667) para Few-shot/Thought-Chain (0,708). Ou seja, diferente de ChatGPT/Claude, aqui o enriquecimento do prompt trouxe ganho. Esse contraste é ótimo para discutir que “a melhor técnica” não é universal; depende do modelo.
- **DeepSeek:** tem seu melhor resultado em Zero-shot (0,375) e piora conforme a técnica fica mais “complexa” (0,292 e 0,250). Isso fornece um argumento relevante: técnicas que aumentam contexto e estrutura podem ser benéficas para modelos mais capazes/alinhados, mas podem degradar modelos que não lidam bem com instruções longas, exemplos ou cadeias de raciocínio.

Figura 3: Desempenho das LLMs - média likert por técnica.



Análise: este gráfico mede a qualidade percebida das respostas por técnica e por LLM, ou seja, é o contraponto subjetivo da figura 2. Isso é essencial na análise, pois não traz apenas a discussão de qual modelo é melhor como também do que se comunica melhor. Dessa forma, temos as seguintes considerações:

- O ChatGPT e o Claude mantêm um alto patamar de nota likert em todas as técnicas, reforçando que não é apenas acerto: há qualidade também nas justificativas. O ChatGPT atinge seu melhor valor em Zero-shot (4,708) e mantém quase o mesmo em Thought-Chain (4,625), mas cai em Few-shot (4,375). Isso fortalece a interpretação de que o Few-shot utilizado pode ter sido menos adequado para o tipo de tarefa ou para o modelo.
- O Gemini quando utiliza técnicas mais estruturadas se beneficia na correção como também na qualidade textual, dessa forma, esta LLM aumenta seu desempenho com prompts mais guiados. Isso porque, houve um crescimento perceptível na nota likert, ele melhora claramente
- O DeepSeek demonstra um contraponto, ele tem Likert relativamente maior em Zero-shot (3,042) e piora em Few-shot/Thought-Chain (2,917 e 2,875). Essa tendência deixa claro que além das notas baixas no acerto/erro, ele também entrega respostas piores de acordo com o aumento de complexidade na técnica utilizada. Uma interpretação plausível é que o modelo se perde nas instruções de prompts mais longos/estruturados.

Figura 4: Desempenho das LLMs - Heatmap da taxa de acerto por item e LLM.

Análise: este gráfico é uma matriz de desempenho objetivo, onde cada célula representa a taxa média de acerto(0 a 1) de uma LLM em um gráfico específico, dentro de uma técnica. A ordenação dos itens foi realizada por acerto global, o que cria um gradiente visual de dificuldade, dessa forma, itens mais fáceis estão no topo, enquanto os mais difíceis estão na base. Com isso, o item 2 é o caso limite positivo, demonstrando-se altamente dominado pelas LLMs. Em contraposto, os itens 1 e 3 são os críticos,

concentrando os menores valores ao longo do heatmap, sustentando a conclusão que são gráficos que necessitam de habilidades de interpretação que normalmente falham, seja por interpretação mais complexa, maior ambiguidade ou raciocínio que não se mantém estável. No mais, há modelos que mantêm um bom desempenho independente

da técnica, como ChatGPT e Claude, além de terem alguns pontos em comum:

- Controle de facilidade no gráfico 2;
- Alta robustez nos gráficos 7 e 8;
- Desempenho máximo recorrente no gráfico 4 em todas as técnicas;
- Gráfico 6 como zona de dificuldade moderada;





Figura 5: Desempenho das LLMs - Distribuição likert por gráfico.



Análise: como todas as LLMs, técnicas e rodadas estão agregadas, cada box representa a distribuição likert de 35 avaliações por item(3 rodadas x 3 técnicas x 4 LLMs). Portanto, ele responde quais gráficos tendem a gerar respostas melhores ou piores, independente do modelo adotado. Dessa forma, há uma heterogeneidade clara que o gráfico 2 possui um erro completamente compreensível. A seguinte, os gráficos 1 e 3 apresentam os piores desempenhos independente do modelo ou técnica, deixando o insight de enunciado ambíguo ou complexa interpretação, nos gerando inúmeras respostas plausíveis. No mais, o item 8 possui boa taxa de acerto (0,67), mas Likert apenas mediano (3,81), sugerindo que mesmo quando o modelo acerta, ele pode não gerar boas respostas, seja por falta de clareza ou com baixo nível de detalhamento e, o mais importante, isso evidencia que

avaliar somente o acerto pode mascarar problemas de usabilidade/compreensão.

Além disso, como este gráfico agrega “tudo junto”, ele não identifica “quem” derruba a nota (qual LLM/técnica/rodada). Isso é uma vantagem e uma limitação: é ótimo para diagnosticar itens problemáticos do instrumento; mas a explicação causal vem do cruzamento com heatmaps por técnica/LLM e boxplots segmentados. Por fim, algumas observações específicas que foram percebidas nas respostas do modelo DeepSeek:

- Para os gráficos 7 e 8 o modelo não conseguiu identificar corretamente os elementos dos gráficos, justificando que não existia nada visível e repetidas vezes gerando respostas completamente desconectadas do conteúdo


visual. A presença de respostas alucinatórias em itens específicos indica que não é uma dificuldade gráfica, mas uma dificuldade própria do modelo utilizado.

- Para o gráfico 5 o modelo classificou a visualização como sendo barras, apesar de se tratar de um gráfico de pizza. Esse tipo de falha é relevante, pois mostra que a escolha do gráfico

define o esquema de leitura. Enquanto as barras priorizam comparações por eixo, o de pizza prioriza proporções e, ao iniciar a análise com identificação equivocada, o modelo constrói explicações com premissas erradas.

Essas evidências qualitativas reforçam que o desempenho pode variar por conta da extração de informações visuais

Figura 6: Desempenho das LLMs - Distribuição likert por rodada, separado por LLM



Análise: o gráfico analisa a estabilidade da qualidade percebida ao longo das três rodadas, mantendo o recorte por LLM. Dessa forma, podemos detalhar os seguintes insights:


- O ChatGPT aumenta e consolida a qualidade percebida conforme as rodadas avançam, entregando respostas bem avaliadas com maior frequência. Isso demonstra que o modelo possui robustez, mantendo alta performance e redução de flutuações negativas ao longo das execuções.
- O Claude tem um padrão de pico na rodada 2 e uma queda na 3. Apesar de se classificar como um dos melhores, pode ser sensível a variação de rodadas dependendo do gráfico e da técnica.
- O Gemini é o que mais oscila durante as rodadas, começa como o melhor em qualidade percebida na Rodada 1 (4,42), cai na Rodada 2 (4,04) e recupera na Rodada 3 (4,25). Isso reforça o papel da variabilidade estocástica entre rodadas em alguns modelos, pois mesmo usando o mesmo procedimento, parte das respostas podem variar.
- O DeepSeek permanece abaixo dos demais em todas as rodadas, melhorando apenas na rodada 3, sugerindo que, embora seja limitado, a forma da aceitabilidade pode ter melhorado em alguns casos.

5.1 Desempenho das LLMs na correção de erros

Os resultados da etapa anterior mostram que o ChatGPT e o Claude são os modelos mais promissores para geração de novos gráficos e correções de erros identificados. Isso se justifica pela combinação de maior desempenho objetivo (acerto) com qualidade percebida (likert) e menos incidência de falhas grosseiras (respostas fora de contexto).

Dessa forma, foi possível detalhar diversos insights na correção de erros e geração gráfica, na sequência, a análise realizada.


Figura 7: Desempenho das LLMs na correção de erros - taxa de acerto



Análise: a visualização apresentada permite identificar se o erro foi pontual, sistemático ou dependente da técnica.

- O ChatGPT garante desempenho máximo independente da técnica, demonstrando correção em relação à etapa anterior, além de manter consistência total sem variação entre as estratégias de prompt.

Figura 8: Desempenho das LLMs na correção de erros - Heatmap do likert por item



Análise: o gráfico mostra uma avaliação qualitativa, que é a clareza e adequação das respostas. Dessa forma:

- O ChatGPT manteve alto padrão em todas as análises, tendo uma dificuldade apenas no gráfico 4, sugerindo que a LLM resolveu bem o problema, apenas houveram falhas no detalhamento e explicação do erro.
- No Claude houve grande dificuldade, tanto na interpretação do gráfico 1 quanto na qualidade de suas respostas, por isso o likert avaliado tão baixo em comparação a outros gráficos. Além disso, a mesma observação no gráfico 3, conseguiu identificar e corrigir o erro, mas teve falhas porque introduziu um erro na escala de um dos eixos..

No mais, o ChatGPT foi o modelo mais consistente na correção, enquanto o Claude foi eficaz, mas com menor uniformidade qualitativa.

Em relação às técnicas, foi possível notar uma maior verbosidade na etapa de respostas do Thought-Chain, com uma explicação mais completa e direcionada aos itens de pesquisa. Já o Few-shot, por ter um contexto e explicação de outro gráfico para a LLM se basear, pode ter atrapalhado os modelos na interpretação, apesar de isso não ter impactado o resultado.

6 Conclusão

6.1 Análise geral

Na etapa 1 (identificação de erros), os resultados indicaram maior variabilidade entre modelos e técnicas de prompt, revelando que parte dos gráficos impuseram maior dificuldade e mostrando que o desempenho das

- O Claude também obteve alto desempenho, não sendo perfeito apenas pelo ponto chave que é o gráfico 1. Isso significa que a falha não foi pontual e também não foi dependente da técnica de prompt, o que descreve uma limitação localizada e não generalizado

LLMs não depende exclusivamente da arquitetura do modelo, como também de características específicas da tarefa visual proposta. Nesse sentido, o ChatGPT e o Claude se destacaram como os melhores modelos, visto o maior desempenho global, ao passo que os demais tiveram muitas limitações em itens críticos.

Já na segunda etapa, ambos os modelos obtiveram desempenho elevado, além de grande consistência qualitativa. No mais, exatamente nesta etapa, foi possível perceber que as diferentes técnicas de prompt deixaram de exercer influência significativa sobre os resultados, sugerindo que, no contexto de correção a capacidade intrínseca do modelo passou a ter maior peso do que a formulação do prompt.

Dessa forma, a articulação entre as duas etapas permite concluir que a avaliação realizada não se restringiu à mensuração do desempenho inicial das LLMs, mas avançou para a análise de sua capacidade de refinamento e correção. Em termos metodológicos, a Etapa 1 foi essencial para mapear limitações, identificar padrões de erro e selecionar os modelos mais robustos, ao passo que a Etapa 2 demonstrou que esses mesmos modelos, sobretudo o ChatGPT, apresentam maior potencial para atuar em tarefas de geração gráfica com correção de erros. Assim, os resultados reforçam que a análise de LLMs em contextos visuais deve considerar não apenas o desempenho inicial diante da tarefa, mas também sua capacidade posterior de revisão, ajuste e melhoria da resposta produzida.

6.1 Trabalhos futuros

7 Referências

- Como sugestão para trabalhos futuros, recomendamos se ampliar a investigação para um conjunto mais diversificado de gráficos, contextos e modelos, de modo a verificar se os padrões observados neste estudo se mantêm em cenários mais complexos. Também se mostra pertinente aprofundar a análise sobre o impacto de diferentes estratégias de prompting e sobre a capacidade das LLMs de realizar correção iterativa de erros em tarefas visuais, incorporando novas rodadas experimentais, métricas complementares e um número maior de casos de teste. Dessa forma, seria possível avançar na compreensão da robustez, da generalização e das limitações desses modelos em aplicações de geração e interpretação gráfica.
- ## 7 Referências
- [1] LAN, X.; LIU, Y. "I came across a junk": Understanding design flaws of data visualization from the public's perspective. *IEEE Transactions on Visualization and Computer Graphics*, v. 31, n. 1, p. 393–403, 2025.
 - [2] VÁZQUEZ, P.-P. Are LLMs ready for visualization? In: *IEEE 17th Pacific Visualization Conference (PacificVis)*, 2024, IEEE, p. 343–352.
 - [3] BENDECK, A.; STASKO, J. An empirical evaluation of the GPT-4 multimodal language model on visualization literacy tasks. *IEEE Transactions on Visualization and Computer Graphics*, v. 31, n. 1, p. 1105–1115, jan. 2025.
 - [4] KHAN, S. R.; CHANDAK, V.; MUKHERJEA, S. Evaluating LLMs for visualization generation and understanding. *Discover Data*, v. 3, n. 15, 2025. <https://doi.org/10.1007/s44248-025-00036-4>
 - [5] BONÁS, V.; SINNONA, M.; SILESS, V.; IARUSSI, E. De-rendering, reasoning, and repairing charts with vision-language models. arXiv:2602.20291, 2026.
 - [6] ALAYRAC, J.-B. et al. Flamingo: a visual language model for few-shot learning. In: *Advances in Neural Information Processing Systems*, v. 35, p. 23716–23736, 2022.
 - [7] RADFORD, A. et al. Learning transferable visual models from natural language supervision. In: *International Conference on Machine Learning (ICML)*, p. 8748–8763, 2021.
 - [8] WU, Tao et al. *Semantic Alignment for Multimodal Large Language Models*. arXiv preprint arXiv:2408.12867, 2024. Disponível em: [arXiv](https://arxiv.org/abs/2408.12867). Acesso em: [24 maio 2026].
 - [9] VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems (NeurIPS)*, v. 30, p. 5998–6008, 2017.
 - [10] KUMAR, P. Large language models (LLMs): survey, technical frameworks, and future challenges. *Artificial Intelligence Review*, v. 57, n. 10, p. 260, ago. 2024.
 - [11] BROWN, T. B. et al. Language models are few-shot learners. In: *Advances in Neural Information Processing Systems (NeurIPS)*, v. 33, p. 1877–1901, 2020.
 - [12] MINAEE, S. et al. Large language models: a survey. arXiv preprint arXiv:2402.06196, 2024.
 - [13] PROMPT ENGINEERING GUIDE. Prompt engineering guide. Disponível em: <https://www.promptingguide.ai>. Acesso em: [27 de Abril de 2026].
 - [14] WEI, J. et al. Chain-of-thought prompting elicits reasoning in large language models. In: *Advances in Neural Information Processing Systems (NeurIPS)*, v. 35, p. 24824–24837, 2022.
 - [15] SHI, Freda et al. *Language Models are Multilingual Chain-of-Thought Reasoners*. In: *International Conference on Learning Representations (ICLR)*, 2023. Disponível em: [OpenReview ICLR](https://openreview.net/forum?id=Z3112017). Acesso em: 24 maio 2026.
 - [16] WILKE, C. *Fundamentals of data visualization: a primer on making informative and compelling figures*. Sebastopol: O'Reilly Media, 2019.
 - [17] HEHMAN, E.; XIE, S. Y. Doing better data visualization. *Advances in Methods and Practices in Psychological Science*, v. 4, n. 4, p. 1–18, 2021.
 - [18] MIDWAY, S. R. Principles of effective data visualization. *Patterns*, v. 1, n. 9, p. 100141, 2020.
 - [19] NGUYEN, V. T.; JUNG, K.; GUPTA, V. Examining data visualization pitfalls in scientific publications. *Visual Computing for Industry, Biomedicine, and Art*, v. 4, n. 1, p. 27, out. 2021. <https://doi.org/10.1186/s42492-021-00092-y>
 - [20] KNAFLIC, C. N. *Storytelling com dados: um guia sobre visualização de dados para profissionais de negócios*. Rio de Janeiro: Alta Books, 2019.